

# 5. 보간법과 회귀분석



# 1. 보간법 (Interpolation)

# 1.1 서론

● 응용 예 : 원자간 pair-wise interaction



● Taylor Series (*one-point approximation*)를 사용할 수 없는 이유

Approximate f(x)=1/x at x=3, using a Taylor expansion at x=1.

$$f^{(n)}(x) = (-1)^n n! x^{-n-1}$$

$$P_n(x) = \sum_{k=0}^n \frac{f^{(k)}(1)}{k!} (x-1)^k = \sum_{k=0}^n (-1)^k (x-1)^k$$

| п          | 0 | 1  | 2 | 3  | 4  | 5   | 6  | 7   |
|------------|---|----|---|----|----|-----|----|-----|
| $P_{o}(3)$ | 1 | -1 | 3 | -5 | 11 | -21 | 43 | -85 |

#### 1.2 Newton

• Taylor Series 와의 관계 (finite divided difference)

Forward difference 
$$f'(x_i) = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i} + O(x_{i+1} - x_i)$$

Backward difference 
$$f'(x_i) = \frac{f(x_i) - f(x_{i-1})}{h} + O(h)$$

Centered difference 
$$f'(x_i) = \frac{f(x_{i+1}) - f(x_{i-1})}{2h} - O(h^2)$$


Example) 다음 함수의 1 차도함수를 x=0.5 에서 h=0.5, 0.25 로 위 세가지 방법을 사용하여 계산하라.(참값 -0.9125)

$$f(x) = -0.1x^4 - 0.15x^3 - 0.5x^2 - 0.25x + 1.2$$

고차 도함수의 유한차분 근사

$$f''(x_i) = \frac{f(x_{i+1}) - 2f(x_i) + f(x_{i-1})}{h^2} + O(h^2)$$

$$f''(x_i) \cong \frac{\frac{f(x_{i+1}) - f(x_i)}{h} - \frac{f(x_i) - f(x_{i-1})}{h}}{h}$$



### ● 1 차 (선형) 보간법

$$f_1(x) = f(x_0) + \frac{f(x_1) - f(x_0)}{x_1 - x_0} (x - x_0)$$

Forward difference

$$f'(x_i) = \frac{f(x_{i+1}) - f(x_i)}{x_{i+1} - x_i} + O(x_{i+1} - x_i)$$

Example) 선형 보간법을 사용하여 In2 를 x = 1~6, x = 1~4 구간에서 계산하고 구간 크기의 영향을 조사하라. (0.3583519, 0.4620981 vs. 0.69314718)

#### ● 2차 보간법

$$f_2(x) = b_o + b_1(x - x_0) + b_2(x - x_0)(x - x_1)$$

$$b_o = f(x_0)$$

$$b_1 = \frac{f(x_1) - f(x_0)}{x_1 - x_0}$$

$$b_2 = \frac{\frac{f(x_2) - f(x_1)}{x_2 - x_1} - \frac{f(x_1) - f(x_0)}{x_1 - x_0}}{x_2 - x_0}$$

Example) x = 1, 4, 6 에서의 값에 기반을 둔 2 차 보간법을 사용하여 In2 값을 구하라.

$$ln 1 = 0$$

ln 4 = 1.386294

ln 6 = 1.791759

$$f_2(x) = 0 + 0.4620981(x-1) + -0.0518731(x-1)(x-4)$$
$$= 0.5658444$$

● Newton 보간 다항식의 일반화

$$f_{n}(x) = b_{o} + b_{1}(x - x_{0}) + \dots + b_{n}(x - x_{0})(x - x_{1}) \dots (x - x_{n-1})$$

$$b_{o} = f(x_{o})$$

$$b_{1} = \frac{f(x_{1}) - f(x_{0})}{x_{1} - x_{0}} = f[x_{1}, x_{0}]$$

$$\frac{f(x_{2}) - f(x_{1})}{x_{2} - x_{1}} - \frac{f(x_{1}) - f(x_{0})}{x_{1} - x_{0}} = f[x_{2}, x_{1}, x_{0}]$$

$$\vdots$$

$$b_{n} = f[x_{n}, x_{n-1}, \dots, x_{1}, x_{0}]$$

$$f[x_{i}, x_{j}, x_{k}] = \frac{f[x_{i}, x_{j}] - f[x_{j}, x_{k}]}{x_{i} - x_{k}}$$

$$f[x_{n}, x_{n-1}, \dots, x_{1}, x_{0}] = \frac{f[x_{n}, x_{n-1}, \dots, x_{1}] - f[x_{n-1}, x_{n-2}, \dots, x_{0}]}{x_{n} - x_{0}}$$

$$f_n(x) = f(x_0) + (x - x_0)f[x_1, x_0] + (x - x_0)(x - x_1)f[x_2, x_1, x_0]$$
$$+ \dots + (x - x_0)(x - x_1) \dots (x - x_{n-1})f[x_n, x_{n-1}, \dots, x_0]$$

| x 	 f(x)              |                                                   | First<br>Divided Differences                      | Second<br>Divided Differences                                    | Third<br>Divided Differences                                                    |  |  |
|-----------------------|---------------------------------------------------|---------------------------------------------------|------------------------------------------------------------------|---------------------------------------------------------------------------------|--|--|
| $x_0$ $f[x_0]$        | $f[x_0, x_1] = \frac{f[x_1] - f[x_0]}{x_1 - x_0}$ | alabaye na a salabaye na kata ta                  | € N. mollonat, pol                                               |                                                                                 |  |  |
| $x_1$                 | $f[x_1]$                                          | $f[x_1, x_2] = \frac{f[x_2] - f[x_1]}{x_2 - x_1}$ | $f[x_0, x_1, x_2] = \frac{f[x_1, x_2] - f[x_0, x_1]}{x_2 - x_0}$ | $f[x_0, x_1, x_2, x_3] = \frac{f[x_1, x_2, x_3] - f[x_0, x_1, x_2]}{x_2 - x_0}$ |  |  |
| $x_2$                 | $f[x_2]$                                          | $f[x_2, x_3] = \frac{f[x_3] - f[x_2]}{x_2 - x_2}$ | $f[x_1, x_2, x_3] = \frac{f[x_2, x_3] - f[x_1, x_2]}{x_3 - x_1}$ | $f[x_1, x_2, x_3, x_4] = \frac{f[x_2, x_3, x_4] - f[x_1, x_2, x_3]}{x_4 - x_1}$ |  |  |
| <i>x</i> <sub>3</sub> | $f[x_3]$                                          | $f[x_3, x_4] = \frac{f[x_4] - f[x_3]}{x_4 - x_3}$ | $f[x_2, x_3, x_4] = \frac{f[x_3, x_4] - f[x_2, x_3]}{x_4 - x_2}$ | $f[x_2, x_3, x_4, x_5] = \frac{f[x_3, x_4, x_5] - f[x_2, x_3, x_4]}{x_5 - x_5}$ |  |  |
| $x_4$                 | $f[x_4]$                                          | $f[x_4, x_5] = \frac{f[x_5] - f[x_4]}{x_5 - x_4}$ | $f[x_3, x_4, x_5] = \frac{f[x_4, x_5] - f[x_3, x_4]}{x_5 - x_3}$ |                                                                                 |  |  |
| <i>x</i> <sub>5</sub> | $f[x_5]$                                          | A5 - A4                                           |                                                                  |                                                                                 |  |  |

```
Subroutine NewtInt (x,y,n,xi,yint,ea)
    LOCAL fdd(n,n)
    DO i = 0, n
       fdd(i,0) = y(i)
    END DO
    DOj = 1, n
       DO i = 0, n-j
          fdd(i,j) = (fdd(i+1,j-1)-fdd(i,j-1)) / (x(i+1)-x(i))
       END DO
    END DO
    xterm = 1
    yint(0) = fdd(0,0)
    DO order = 1, n
        xterm = xterm * (xi - x(order-1))
        yint(order) = yint(order-1) + fdd(0,order) * xterm
        ea(order) = yint(order) - yint(order-1)
    END DO
END NewtInt
```

#### 1.3 Lagrange Polynomials

$$f_n(x) = \sum_{k=0}^{n} L_{n,k}(x) f(x_k)$$

$$L_{n,k}(x) = \prod_{\substack{j=0 \ j \neq k}}^{n} \frac{x - x_j}{x_k - x_j}$$


● 선형 보간 (n = 1)

$$f_1(x) = \frac{x - x_1}{x_0 - x_1} f(x_0) + \frac{x - x_0}{x_1 - x_0} f(x_1)$$

● 2 차 보간

$$f_2(x) = \frac{x - x_1}{x_0 - x_1} \frac{x - x_2}{x_0 - x_2} f(x_0) + \frac{x - x_0}{x_1 - x_0} \frac{x - x_2}{x_1 - x_2} f(x_1)$$
$$+ \frac{x - x_0}{x_2 - x_0} \frac{x - x_1}{x_2 - x_1} f(x_2)$$

$$L_{n,k}(x) = \frac{(x-x_0)\cdots(x-x_{k-1})(x-x_{k+1})\cdots(x-x_n)}{(x_k-x_0)\cdots(x_k-x_{k-1})(x_k-x_{k+1})\cdots(x_k-x_n)}$$



 $L_{n,k}(x)$ 는  $x = x_k$  에서는 1, 나머지 x 값에서는 0 이 되는 n차 함수이다.

 $\Rightarrow f_n(x)$ 는 모든 n+1 개의 데이터 점들을 정확하게 통과하는 유일한 n차 다항식이 된다.

### nth Lagrange Interpolating Polynomial

$$P_n(x) = f(x_0)L_{n,0}(x) + \dots + f(x_n)L_{n,n}(x) = \sum_{k=0}^n f(x_k)L_{n,k}(x),$$

where

$$L_{n,k}(x) = \frac{(x - x_0)(x - x_1) \cdots (x - x_{k-1})(x - x_{k+1}) \cdots (x - x_n)}{(x_k - x_0)(x_k - x_1) \cdots (x_k - x_{k-1})(x_k - x_{k+1}) \cdots (x_k - x_n)}$$

for each  $k = 0, 1, \ldots, n$ .

● N 차 결과를 n+1 차에 사용하도록 개선 → Neville's method

Example) 1, 2 차 Lagrange 보간 다항식을 이용하여 In2 값을 구하라.

ln 1 = 0

ln 4 = 1.386294

ln 6 = 1.791759

1, 2 차 Newton 보간 다항식의 결과와 비교하라.

Example) Lagrange 보간 다항식은 Newton 제차분 보간 다항식으로부터 유도될 수 있는 것임을 보여라. (1 차인 경우를 고려해 볼 것)

```
Subroutine Lagrng (x,y,n,xi)

sum = 0

DO i = 0, n

product = y(i)

DO j = 0, n

IF i \neq j THEN

product = product * (x - x(j)) / (x(i) - x(j))

ENDIF

END DO


sum = sum + product


END DO

Lagrng = sum


END Lagrng
```

# 1.4 Spline (Piecewise polynomial approximation)





# ● 2차 스플라인



for n+1 data point

$$f_i(x) = a_i x^2 + b_i x + c_i$$
; 총 미지수 개수 = 3 $n$ 

1. 내부 절점에서 이웃하는 다항식들의 함수 값이 같아야 한다.

$$a_{i-1}x_{i-1}^{2} + b_{i-1}x_{i-1} + c_{i-1} = f(x_{i-1})$$

$$a_{i}x_{i-1}^{2} + b_{i}x_{i-1} + c_{i} = f(x_{i-1})$$
(2*n*-2)

2. 첫번째와 마지막 함수는 반드시 끝점을 통과해야만 한다.

$$a_1 x_0^2 + b_1 x_0 + c_0 = f(x_0)$$

$$a_n x_n^2 + b_n x_n + c_n = f(x_n)$$
(2)

3. 내부 절점에서 이웃한 다항식들의 1 차 도함수는 같아야 한다.

$$2a_{i-1}x_{i-1} + b_{i-1} = 2a_ix_{i-1} + b_i (n-1)$$

4.2차 도함수가 첫 번째 데이터 점에서 0이라고 가정한다.

$$a_1 = 0 \tag{1}$$

Example) 다음 데이터를 2 차 스플라인으로 적합시키고 x=5 에서의 값을 구하라

| Х   | f(x) |
|-----|------|
| 3.0 | 2.5  |
| 4.5 | 1.0  |
| 7.0 | 2.5  |
| 9.0 | 0.5  |

$$20.25a_1 + 4.5b_1 + c_1 = 1.0$$

$$20.25a_2 + 4.5b_2 + c_2 = 1.0$$

$$49a_2 + 7b_2 + c_2 = 2.5$$

$$49a_3 + 7b_3 + c_3 = 2.5$$

$$9a_1 + 3b_1 + c_1 = 2.5$$

$$81a_3 + 9b_3 + c_3 = 0.5$$

$$9a_1 + b_1 = 9a_2 + b_2$$

$$14a_2 + b_2 = 14a_3 + b_3$$

$$a_1 = 0$$
  $b_1 = -1$   $c_1 = 5.5$ 

$$a_2 = 0.64$$
  $b_2 = -6.76$   $c_2 = 18.46$ 

$$a_3 = -1.6$$
  $b_3 = 24.6$   $c_3 = -91.3$ 

$$f_1(x) = -x + 5.5$$
  $3.0 \le x \le 4.5$ 

$$f_2(x) = 0.64x^2 - 6.76x + 18.46$$
  $4.5 \le x \le 7.0$ 

$$f_3(x) = -1.6x^2 + 24.6x - 91.3$$
  $7.0 \le x \le 9.0$ 

$$f_2(5) = 0.64(5)^2 - 6.76(5) + 18.46 = 0.66$$

● 3 차 (cubic) 스플라인

$$f_i(x) = a_i x^3 + b_i x^2 + c_i x + d_i$$

- 1. 함수 값은 내부 절점에서 같아야 한다. [2*n*-2]
- 2. 첫 번째와 마지막 함수는 양 끝점을 통과해야 한다. [2]
- 3. 내부 절점에서 1 차 도함수는 같아야 한다. [n-1]
- 4. 내부 절점에서 2차 도함수도 같아야 한다. [n-1]
- 5. 양 끝점에서의 2차 도함수는 0이라고 가정한다. [2] (2차 도함수가 0이 아니라면 그 정보로 조건을 대체)

Method 1

$$f_i(x) = a_i + b_i(x - x_i) + c_i(x - x_i)^2 + d_i(x - x_i)^3$$

Method 2

각 구간 함수의 2 차 도함수를 다음과 같이 1 차 Lagrange 보간 다항식으로 표현.

$$f_{i}^{"}(x) = f_{i}^{"}(x_{i-1}) \frac{x - x_{i}}{x_{i-1} - x_{i}} + f_{i}^{"}(x_{i}) \frac{x - x_{i-1}}{x_{i} - x_{i-1}}$$

각 함수 값이  $x = x_{i-1}$  에서  $f(x_{i-1})$ ,  $x = x_i$  에서  $f(x_i)$  값을 가져야한다는 2개의 조건으로부터 적분 상수 값을 구하고 다음 표현식을 얻는다.

$$f_{i}(x) = \frac{f_{i}''(x_{i-1})}{6(x_{i} - x_{i-1})} (x_{i} - x)^{3} + \frac{f_{i}''(x_{i})}{6(x_{i} - x_{i-1})} (x - x_{i-1})^{3}$$

$$+ \left[ \frac{f(x_{i-1})}{x_{i} - x_{i-1}} - \frac{f''(x_{i-1})(x_{i} - x_{i-1})}{6} \right] (x_{i} - x)$$

$$+ \left[ \frac{f(x_{i})}{x_{i} - x_{i-1}} - \frac{f''(x_{i})(x_{i} - x_{i-1})}{6} \right] (x - x_{i-1})$$

From 
$$f'_{i+1}(x_i) = f'_{i}(x_i)$$

$$(x_{i} - x_{i-1})f''(x_{i-1}) + 2(x_{i+1} - x_{i-1})f''(x_{i}) + (x_{i+1} - x_{i})f''(x_{i+1})$$

$$= \frac{6}{x_{i+1} - x_{i}} [f(x_{i+1}) - f(x_{i})] + \frac{6}{x_{i} - x_{i-1}} [f(x_{i-1}) - f(x_{i})]$$

Example) 다음 데이터를 3 차 스플라인으로 적합시키고 x=5 에서의 값을 구하라

| X   | f(x) |
|-----|------|
| 3.0 | 2.5  |
| 4.5 | 1.0  |
| 7.0 | 2.5  |
| 9.0 | 0.5  |

$$(4.5-3)f''(3) + 2(7-3)f''(4.5) + (7-4.5)f''(7)$$

$$= \frac{6}{7-4.5}(2.5-1) + \frac{6}{4.5-3}(2.5-1)$$

8 
$$f''(4.5) + 2.5 f''(7) = 9.6$$
  
2.5  $f''(4.5) + 9 f''(7) = -9.6$ 

$$f''(4.5) = 1.67909$$
  
 $f''(7) = -1.53308$ 

$$f_1(x) = \frac{1.67909}{6(4.5-3)}(x-3)^3 + \frac{2.5}{4.5-3}(4.5-x) + \left[\frac{1}{4.5-3} - \frac{1.67909(4.5-3)}{6}\right](x-3)$$

$$f_1(x) = 0.186566(x-3)^3 + 1.666667(4.5-x) + 0.246894(x-3)$$

$$f_2(x) = 0.111939(7-x)^3 - 0.102205(x-4.5)^3 - 0.299621(7-x) + 1.638783(x-4.5)$$

$$f_3(x) = -0.127757(9-x)^3 + 1.761027(9-x) + 0.25(x-7)$$

$$f_2(5) = 1.102886$$

```
SUBROUTINE Spline (x,y,n,xu,yu,dy,d2y)

LOCAL e(n), f(n), g(n), r(n), d2x(n)

CALL Tridiag(x,y,n,e,f,g,r)

CALL Gauss

CALL Interpol(x,y,n,d2x,xu,yu,dy,d2y)

END Spline
```


**END Tridiag** 


SUBROUTINE Tridiag 
$$(x,y,n,e,f,g,r)$$
  
 $f(1) = 2 * (x(2)-x(0))$   
 $g(1) = (x(2)-x(1))$   
 $r(1) = 6/(x(2)-x(1)) * (y(2)-y(1)) + 6/(x(1)-x(0)) * (y(0)-y(1))$   
DO  $i = 2, n-2$   
 $e(i) = (x(i) - x(i-1))$   
 $f(i) = 2 * (x(i+1) - x(i-1))$   
 $g(i) = (x(i+1) - x(i))$   
 $r(i) = 6/(x(i+1)-x(i))*(y(i+1)-y(i)) + 6/(x(i)-x(i-1)) * (y(i-1)-y(i))$   
ENDDO  
 $e(n-1) = (x(n-1) - x(n-2))$   
 $f(n-1) = 2 * (x(n) - x(n-2))$   
 $r(n-1) = 6/(x(n)-x(n-1)) * (y(n)-y(n-1))$   
 $+ 6/(x(n-1)-x(n-2)) * (y(n-2)-y(n-1))$ 


```
SUBROUTINE Interpol (x,y,n,d2x,xu,yu,dy,d2y)
       flag = 0
       i = 1
       DO
           IF xu >= x(i-1) AND xu =< x(i) THEN
              c1 = d2x(i-1)/6/(x(i)-x(i-1))
              c2 = d2x(i)/6/(x(i)-x(i-1))
              c3 = y(i-1)/(x(i)-x(i-1)) - d2x(i-1) * (x(i) - x(i-1))/6
              c4 = y(i)/(x(i)-x(i-1)) - d2x(i) * (x(i) - x(i-1))/6
              t1 = c1 * (x(i) - xu)^3
              t2 = c2 * (xu - x(i-1))^3
              t3 = c3 * (x(i) - xu)
              t4 = c4 * (xu - x(i-1))
              yu = t1 + t2 + t3 + t4
              t1 = -3 * c1 * (x(i)-xu)^2
              t2 = 3 * c2 * (xu - x(i-1))^2
              t3 = - c3
              t4 = c4
              dy = t1 + t2 + t3 + t4
              t1 = 6 * c1 * (x(i) - xu)
              t2 = 6 * c2 * (xu - x(i-1))
              d2y = t1 + t2
              flag = 1
           ELSE
              | = | + 1|
          ENDIF
           IF i = n + 1 OR flag = 1 EXIT
       ENDDO
       IF flag = 0 THEN
          Print "outside range"
          Pause
       ENDIF
       END Interpol
```

# 2. 회귀분석 (Regression)

| $x_i$ | $y_i$ | $x_i$ | $y_i$ |
|-------|-------|-------|-------|
| 1     | 1.3   | 6     | 8.8   |
| 2     | 3.5   | 7     | 10.1  |
| 3     | 4.2   | 8     | 12.5  |
| 4     | 5.0   | 9     | 13.0  |
| 5     | 7.0   | 10    | 15.6  |








#### 2.1 Discrete Least Square

● 선형회귀분석 도출 과정



회귀분석에 부적절한 "최적" 판별조건의 예들. (a) 잔차의 합을 최소화함, (b) 잔차의 절대값의 합을 최소화함, (c) 각 점의 최대오차값을 최소화함.

- (a) Minimizing sum of deviation
- (b) Minimizing sum of absolute deviation
- (c) Minimizing maximum deviation (minimax)

● 선형 회귀분석 (Minimizing sum of squares of deviation)

$$y = a_0 + a_1 x + e$$

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$

$$\frac{\partial S_r}{\partial a_0} = -2 \sum_{i=1}^n (y_i - a_0 - a_1 x_i) = 0$$

$$\frac{\partial S_r}{\partial a_1} = -2 \sum_{i=1}^n x_i (y_i - a_0 - a_1 x_i) = 0$$

$$na_0 + \left(\sum x_i\right) a_1 = \sum y_i$$

$$\left(\sum x_i\right) a_0 + \left(\sum x_i^2\right) a_1 = \sum x_i y_i$$

$$a_{1} = \frac{n\sum x_{i}y_{i} - \sum x_{i}\sum y_{i}}{n\sum x_{i}^{2} - (\sum x_{i})^{2}}$$


$$a_0 = \overline{y} - a_1 \overline{x}$$

| $x_i$ | $y_i$ | $x_i^2$ | $x_i y_i$ | $P(x_i) = 1.538x_i - 0.360$                        |
|-------|-------|---------|-----------|----------------------------------------------------|
| 1     | 1.3   | 1       | 1.3       | 1.18                                               |
| 2     | 3.5   | 4       | 7.0       | 2.72                                               |
| 3     | 4.2   | 9       | 12.6      | 4.25                                               |
| 4     | 5.0   | 16      | 20.0      | 5.79                                               |
| 5     | 7.0   | 25      | 35.0      | 7.33                                               |
| 6     | 8.8   | 36      | 52.8      | 8.87                                               |
| 7     | 10.1  | 49      | 70.7      | 10.41                                              |
| 8     | 12.5  | 64      | 100.0     | 11.94                                              |
| 9     | 13.0  | 81      | 117.0     | 13.48                                              |
| 10    | 15.6  | 100     | 156.0     | 15.02                                              |
| 55    | 81.0  | 385     | 572.4     | $E = \sum_{i=1}^{10} (y_i - P(x_i))^2 \approx 2.3$ |

# ● 오차의 정량화

$$S_r = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - a_0 - a_1 x_i)^2$$

표준편차 
$$s_{y/x} = \sqrt{\frac{S_r}{n-2}}$$



결정계수 (Coefficient of determination)  $r^2 = \frac{S_t - S_r}{S_t}$ 


 $S_{\scriptscriptstyle t}\colon {\it y}$  의 평균에 대한 제곱합


상관계수 r

$$r = \frac{n\sum x_{i}y_{i} - \sum x_{i}\sum y_{i}}{\sqrt{n\sum x_{i}^{2} - (\sum x_{i})^{2}} \sqrt{n\sum y_{i}^{2} - (\sum y_{i})^{2}}}$$

```
SUB Regress (x, y, n, a1, a0, syx, r2)
     sumx = 0; sumxy = 0; st = 0
     sumy = 0; sumx2 = 0; sr = 0
     DOI = 1, n
        sumx = sumx + x(i)
        sumy = sumy + y(i)
        sumxy = sumxy + x(i)*y(i)
        sumx2 = sumx2 + x(i)*x(i)
     ENDDO
     xm = sumx / n
     ym = sumy / n
     a1 = (n*sumxy - sumx*sumy)/(n*sumx2 - sumx*sumx)
     a0 = ym - a1*xm
     DOi = 1, n
        st = st + (y(i) - ym)^2
        sr = sr + (y(i) - a1*x(i) - a0)^2
     ENDDO
     syx = (sr/(n-2))^{0.5}
     r2 = (st - sr) / st
END Regress
```

# ● 비선형 관계식의 선형화





(a) 지수 방정식, (b) 멱 방정식, (c) 포화성장률 방정식. (d), (e), (f)는 간단한 변환에 의한 선형 방정식.

#### 2.2 다항식 회귀분석

$$y = a_0 + a_1 x + a_2 x^2 + e$$

$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1 x_i - a_2 x_i^2)^2$$

$$\frac{\partial S_r}{\partial a_0} = -2\sum \left(y_i - a_0 - a_1 x_i - a_2 x_i^2\right)$$

$$\frac{\partial S_r}{\partial a_1} = -2\sum_i x_i \left( y_i - a_0 - a_1 x_i - a_2 x_i^2 \right)$$

$$\frac{\partial S_r}{\partial a_2} = -2 \sum_i x_i^2 \left( y_i - a_0 - a_1 x_i - a_2 x_i^2 \right)$$

$$(n)a_0 + \left(\sum x_i\right)a_1 + \left(\sum x_i^2\right)a_2 = \sum y_i$$
$$\left(\sum x_i\right)a_0 + \left(\sum x_i^2\right)a_1 + \left(\sum x_i^3\right)a_2 = \sum x_i y_i$$
$$\left(\sum x_i^2\right)a_0 + \left(\sum x_i^3\right)a_1 + \left(\sum x_i^4\right)a_2 = \sum x_i^2 y_i$$

#### Example)

| <b>x</b> i | yi xeb - X    | $(y_i - \overline{y})^2$ | $(y_i - a_0 - a_1x_i - a_2x_i^2)$ |
|------------|---------------|--------------------------|-----------------------------------|
| 0          | 2.1           | 544.44                   | 0.14332                           |
| 4.56       | 2/5 /7.7/3 /0 | 314.47                   | 1.00286                           |
| 2          | 13.6          | 140.03                   | 1.08158                           |
| 3          | 27.2          | 3.12                     | 0.80491                           |
| 4          | 40.9          | 239.22                   | 0.61951                           |
| 5          | 61.1          | 1272.11                  | 0.09439                           |
| Σ          | 152.6         | 2513.39                  | 3.74657                           |
|            |               |                          |                                   |

$$m = 2$$
  $\sum x_i = 15$   $\sum x_i^4 = 979$   
 $n = 6$   $\sum y_i = 152.6$   $\sum x_i y_i = 585.6$   
 $\overline{x} = 2.5$   $\sum x_i^2 = 55$   $\sum x_i^2 y_i = 2488.8$   
 $\overline{y} = 25.433$   $\sum x_i^3 = 225$ 

$$\frac{(n)a_0 + \left(\sum x_i\right)a_1 + \left(\sum x_i^2\right)a_2 = \sum y_i}{\left(\sum x_i\right)a_0 + \left(\sum x_i^2\right)a_1 + \left(\sum x_i^3\right)a_2 = \sum x_i y_i} \\
\left(\sum x_i^2\right)a_0 + \left(\sum x_i^3\right)a_1 + \left(\sum x_i^4\right)a_2 = \sum x_i^2 y_i}$$


$$\begin{bmatrix}
6 & 15 & 55 \\
15 & 55 & 225 \\
55 & 225 & 979
\end{bmatrix}
\begin{cases}
a_0 \\
a_1 \\
a_2
\end{cases} = \begin{cases}
152.6 \\
585.6 \\
2488.8
\end{cases}$$

$$y = 2.47857 + 2.35929x + 1.86071x^2$$

$$s_{y/x} = \sqrt{\frac{3.74657}{6-3}} = 1.12$$


$$r^2 = \frac{2513.39 - 3.74657}{2513.39} = 0.99851$$

$$r = 0.99925$$



### 2.3 다중 선형 회귀분석

$$y = a_0 + a_1 x_1 + a_2 x_2 + e$$



$$S_r = \sum_{i=1}^n (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})^2$$

$$\frac{\partial S_r}{\partial a_0} = -2\sum (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})$$

$$\frac{\partial S_r}{\partial a_1} = -2\sum x_{1i} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})$$

$$\frac{\partial S_r}{\partial a_2} = -2\sum x_{2i} (y_i - a_0 - a_1 x_{1i} - a_2 x_{2i})$$

$$\begin{bmatrix} n & \Sigma x_{1i} & \Sigma x_{2i} \\ \Sigma x_{1i} & \Sigma x_{1i}^2 & \Sigma x_{1i} x_{2i} \\ \Sigma x_{2i} & \Sigma x_{1i} x_{2i} & \Sigma x_{2i}^2 \end{bmatrix} \begin{Bmatrix} a_0 \\ a_1 \\ a_2 \end{Bmatrix} = \begin{Bmatrix} \Sigma y_i \\ \Sigma x_{1i} y_i \\ \Sigma x_{2i} y_i \end{Bmatrix}$$

#### 2.4 선형최소제곱의 일반화

$$y = a_0 z_0 + a_1 z_1 + a_2 z_2 + \dots + a_m z_m + e$$

# ${Y}=[Z]{A}+{E}$

$$[Z] = \begin{bmatrix} z_{01} & z_{11} & \cdots & z_{m1} \\ z_{02} & z_{12} & \cdots & z_{m2} \\ \vdots & \vdots & \vdots & \vdots \\ z_{0n} & z_{1n} & \cdots & z_{mn} \end{bmatrix}$$

m: 모델 변수의 수 n: data point 의 수

 $\{ Y \}^T = [y_1 \ y_2 \ \cdots \ y_n]; y 의 관측값$ 

 $\left\{ \mathcal{A}\right\} ^{\mathsf{T}}=\left[ \mathbf{a}_{0}\;\mathbf{a}_{1}\;\cdots\;\mathbf{a}_{n}\right] ;\;$ 미지계수의 열백터

 $\{E\}^T = [e_1 e_2 \cdots e_n]; 잔차의 열벡터$ 

$$S_r = \sum_{i=1}^{n} \left( y_i - \sum_{j=0}^{m} a_j z_{ji} \right)^2$$

# $[[Z]^{T}[Z]]{A}={[Z]^{T}{Y}}$

※ 단순선형회귀분석, 다항식회귀분석, 다중회귀분석 등 세가지 접근 방식이 모두 동일하며 같은 행렬식으로 간단하게 표현할 수 있다.

미지계수 {A}는 역행렬법으로 다음과 같이 구할 수 있다.

 ${A}=[[Z]^{T}[Z]]^{-1}\{[Z]^{T}{Y}\}$ 

# 2.5 비선형 회귀분석 (Gauss-Newton 방법)

$$f(x) = a_0(1 - e^{-a_1x}) + e^{-a_1x}$$

$$y_i = f(x_i) + e_i$$

Taylor 전개

Taylor 전개 
$$f(x_i)_{j+1} = f(x_i)_j + \frac{\partial f(x_i)_j}{\partial a_0} \Delta a_0 + \frac{\partial f(x_i)_j}{\partial a_1} \Delta a_1$$
  $j \colon$  초기 가정값,  $j+1 \colon$  예측 
$$\Delta a_0 = a_{0,j+1} - a_{0,j} \qquad \qquad \Delta a_1 = a_{1,j+1} - a_{1,j}$$

원래의 비선형 모델을 선형 모델로 변환

$$y_i - f(x_i)_j = \frac{\partial f(x_i)_j}{\partial a_0} \Delta a_0 + \frac{\partial f(x_i)_j}{\partial a_1} \Delta a_1 + e_i$$

# $\{D\}=[Z_i]\{\Delta A\}+\{E\}$

$$[Z_{j}] = \begin{bmatrix} \partial f_{1} / \partial a_{0} & \partial f_{1} / \partial a_{1} \\ \partial f_{2} / \partial a_{0} & \partial f_{2} / \partial a_{0} \\ \vdots & \vdots \\ \partial f_{n} / \partial a_{0} & \partial f_{n} / \partial a_{0} \end{bmatrix}$$

$$\{D\} = \begin{cases} y_1 - f(x_1) \\ y_2 - f(x_2) \\ \vdots \\ y_n - f(x_n) \end{cases} \qquad \{\Delta A\} = \begin{cases} \Delta a_0 \\ \Delta a_1 \\ \vdots \\ \Delta a_m \end{cases}$$

선형최소제곱을 적용

# $[[Z_i]^T[Z_i]]{\Delta A}={[Z]^T\{D\}}$

$$a_{0,j+1} = a_{0,j} + \Delta a_0 \qquad a_{1,j+1} = a_{1,j} + \Delta a_1$$

Example)  $f(x; a_0, a_1) = a_0(1 - e^{-a_1 x})$ 

| X | 0.25 | 0.75 | 1.25 | 1.75 | 2.25 |  |
|---|------|------|------|------|------|--|
| Υ | 0.28 | 0.57 | 0.68 | 0.74 | 0.79 |  |

$$\frac{\partial f}{\partial a_0} = 1 - e^{-a_1 x}$$

$$\frac{\partial f}{\partial a_1} = a_0 x e^{-a_1 x}$$

$$[Z_0] = \begin{bmatrix} 0.2212 & 0.1947 \\ 0.5276 & 0.3543 \\ 0.7135 & 0.3581 \\ 0.8262 & 0.3041 \\ 0.8946 & 0.2371 \end{bmatrix}$$
 
$$[Z_0]^T [Z_0] = \begin{bmatrix} 2.3193 & 0.9489 \\ 0.9489 & 0.4404 \end{bmatrix}$$

$$[Z_0]^T[Z_0] = \begin{bmatrix} 2.3193 & 0.9489 \\ 0.9489 & 0.4404 \end{bmatrix}$$

$$\begin{bmatrix} [Z_0]^T [Z_0] \end{bmatrix}^{-1} = \begin{bmatrix} 3.6397 & -7.8421 \\ -7.8421 & 19.1678 \end{bmatrix}$$

$$\{D\} = \begin{cases} 0.28 - 0.2212 \\ 0.57 - 0.5276 \\ 0.68 - 0.7135 \\ 0.74 - 0.8262 \\ 0.79 - 0.8946 \end{cases} = \begin{cases} 0.0588 \\ 0.0424 \\ -0.0335 \\ -0.0862 \\ -0.1046 \end{cases}$$
 
$$[Z_0]^T \{D\} = \begin{bmatrix} -0.1533 \\ -0.0365 \end{bmatrix}$$

$$[Z_0]^T \{D\} = \begin{bmatrix} -0.1533 \\ -0.0365 \end{bmatrix}$$

$$\Delta A = \begin{cases} -0.2714 \\ 0.5019 \end{cases} \qquad \begin{cases} a_0 \\ a_1 \end{cases} = \begin{cases} 1.0 \\ 1.0 \end{cases} + \begin{cases} -0.2714 \\ 0.5019 \end{cases} = \begin{cases} 0.7286 \\ 1.5019 \end{cases}$$

반복 계산을 통해 얻은 최종 결과

 $a_0 = 0.79186$ ,  $a_1 = 1.6751$ , 잔차제곱합: 0.000662

- ▶ 프로그램에서는 편미분을 위해 차분방정식 사용  $\frac{\partial f}{\partial a_{k}} \cong \frac{f(x_{i}; a_{0}, \dots, a_{k} + \delta a_{k}, \dots, a_{m}) - f(x_{i}; a_{0}, \dots, a_{k}, \dots, a_{m})}{\delta a_{k}}$
- ▶ 수렴이 늦고 진동이 심하며, 수렴이 보장되지 않는 단점. 비선형 최적화 기법을 통해 잔차 제곱합을 최소화하도록 매개변수를 조절

$$S_r = \sum_{i=1}^n \left( y_i - a_0 (1 - e^{-a_1 x_i}) \right)^2$$